

Линеаризация механизма внимания в трансформерных сегментаторах

«Цифровые ресурсы в научном исследовании»

Студент: Салимли А. М., гр. 5140201/60301


Преподаватель: к.т.н. Моторин Д. Е.

Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и кибербезопасности

Санкт-Петербург, 2026

- 1 Введение
- 2 Постановка проблемы
- 3 Методы линеаризации
- 4 Результаты
- 5 Заключение
- 6 Список литературы

- Самовнимание обеспечивает моделирование глобальных зависимостей уже на ранних стадиях сегментатора
- Вычислительная сложность самовнимания составляет $O(N^2)$ по числу пикселей N
- Механизм ESA в SegFormer снижает сложность лишь до $O(N^2/R)$
- Линеаризация направлена на достижение сложности $O(N)$ при сохранении глобального контекста



Архитектура SegFormer [1]


Общая проблема

Моделирование дальнего контекста требует самовнимания со сложностью $O(N^2)$, где $N = H \times W$

Группа	Работы	Данные	Мера эффективности
Сцены	SegFormer, LSNet, RTLinearFormer, HLSCM-ViT	Cityscapes, ADE20K, COCO	FPS на полном кадре
ДЗЗ и промышленность	GLANet, ABCFNet, LPT-Net, CA-UNet, MS-LCFNet, FESS-SAM	чаще собственные	память, FLOPs
Медицина	MLFormer, MASA-VMUNet, WTP-MILA-UNet, CLT-MambaSeg, Snake-RWKV, UUEKAN, PMP	КТ, МРТ, УЗИ	параметры, FLOPs

Постановка проблемы: что считается узким местом

- **Вычислительная сложность внимания** - LSNet, RTLinearFormer, GLANet
- **Деградация карты внимания** после линейризации: ранг 71 из 128 (HLSTM-ViT, UUEKAN)
- **Ограниченный объем выборки** - WTP-MILA-UNet, CLT-MambaSeg
- **Нарушение непрерывности** при развертке 2D в 1D (Snake-RWKV)
- **Квадратичное внимание как точка отсчета** - FESS-SAM



Обычное и непрерывное сканирование [15]

Методы: пять семейств линеаризации


Семейство	Работы	Сложность
Сжатие K, V с softmax (ESA)	SegFormer	$O(N^2/R)$
Ядерное линейное внимание	LSNet, RTLinearFormer, GLANet, ABCFNet, MLFormer, WTP-MILA-UNet, MS-LCFNet, UUEKAN	$O(Nd^2)$
Иные приближения softmax	CLT-MambaSeg, PMP, HLMS-ViT	$O(N)$
SSM / RWKV со сканированием	MASA-VMUNet, Snake-RWKV	$O(N)$
«Линейные» лишь по названию	LPT-Net, CA-UNet	не по N

Ядерное внимание


$$O_i = \frac{\phi(Q_i) \sum_j \phi(K_j)^T V_j}{\phi(Q_i) \sum_j \phi(K_j)^T}$$

Методы: чем дополняют линейное внимание

- Размещение на глубоких стадиях с низким пространственным разрешением
- Сверточные ветви и гейты - RTLinearFormer, MLFormer, ABCFNet
- Выборочный softmax на $2\sqrt{N}$ токенах - HLMS-ViT
- Фокусирующее ядро - MS-LCFNet, UUEKAN



LiteCMSA в RTLinearFormer [3]



Гибридный модуль HLMS [4]

Результаты: линейное vs квадратичное в одной архитектуре

Работа	Датасет, метрика	Квадр.	Линейн.	Δ качества	Стоимость
GLANet	вход 128^2 , память	16.5 ГБ	44 МБ	-	×375 меньше
ABCFNet	Potsdam, mIoU	87.22	87.48	+0.26	22 → 64 FPS
CLT-MambaSeg	ISIC-2016, IoU	90.98	91.05	+0.07	8.55 → 7.02 G
MLFormer	Synapse, DSC	77.91	79.24	+1.33	10.3 → 12.0 мс
RTLinearFormer	Cityscapes, mIoU	78.86	78.41	-0.45	56 → 67 FPS
HLSTM-ViT	COCO, AP ^m	32.3*	31.2	-1.1	≈

* гибрид с выборочным softmax

- На медицинских изображениях малого размера линейаризация не снижает точность
- На сценах высокого разрешения потеря точности составляет 0.5-1.7 п.п. mIoU

Результаты: скорость сегментаторов сцен

Модель	Внимание	Датасет	Разрешение	mIoU	FPS	GPU
SegFormer-B0	ESA	Cityscapes	кор. сторона 1024	76.2	15.2	V100
LSNet	ReLU, $O(N)$	Cityscapes	1024^2	73.94	130.2	3080
RTLinerFormer	ReLU, $O(N)$	Cityscapes	1024×2048	78.41	66.7	3090
DDRNet-23	нет	Cityscapes	1024×2048	79.5	51.4	3090
SegFormer-B0	ESA	ADE20K	512^2	37.4	84.4	3090
RTLinerFormer	ReLU, $O(N)$	ADE20K	512^2	35.7	107.3	3090

Вывод

Замена ESA линейным вниманием обеспечивает ускорение в 1.3 раза при снижении mIoU на 1.7 п.п. (одинаковые GPU и разрешение)

Результаты: число операций и задержка

Модель	Механизм	FLOPs (G)	Задержка (мс)	Dice (%)
UNet	свертки	160.44	9.26	78.01
TransUNet	квадратичное	133.47	15.74	78.88
SCSegamba	Mamba	17.75	44.50	74.17
Snake-RWKV	RWKV	45.21	34.23	80.85

Вход 512×512 , четыре датасета артерий [15]

- Модели со сканированием уступают квадратичным по задержке при меньшем числе FLOPs
- Эффективность линеаризации корректно оценивать по измеренной задержке

Результаты: тонкие протяженные объекты

Модель (тоннель)	Внимание	FLOPs (G)	FPS	Mean IoU
UNet	нет	13.8	49.5	0.393
SegFormer-B5	ESA	99.7	17.4	0.651
ViT-Adapter	квадратичное	227.9	16.7	0.765
FESS-SAM	квадратичное	364.6	4.1	0.819

Кабели, контактный провод, трубопроводы в тоннеле метро [10]

- Ошибки линейных моделей сосредоточены на тонких структурах: столбах (RTLinearFormer), линейных объектах (LPT-Net), ветвях сосудов (Snake-RWKV)
- На дорогах DeepGlobe ABCFNet превосходит UNet++ лишь на 0.3 п.п. IoU

Результаты: сопоставимость результатов различных работ

Модель	Механизм	Synapse (MLFormer)	Synapse (MASA)	GFLOPs
TransUNet	самовнимание	77.48	77.48	88.91
VM-UNet	VMamba	82.38	81.08	4.11
MLFormer	MLLA	83.07	-	9.04
MASA-VMUNet	VMamba	-	84.36	4.53

- Результаты одной базовой модели расходятся на 1.3 п.п. DSC в разных статьях
- На BUSI значения Dice варьируются от 74.23% до 92.32% вследствие различных разбиений
- Замеры выполнены на GPU от RTX 3060 до RTX 5090, поэтому FPS несопоставимы

- Критерий эффективности зависит от области: FPS (сцены), память (ДЗЗ), параметры и FLOPs (медицина)
- Ядерное линейное внимание является наиболее распространенным методом линеаризации
- Потеря точности составляет 0.5-1.7 п.п. mIoU на сценах и отсутствует на малых входах
- Снижение FLOPs не гарантирует снижения задержки, особенно для Mamba и RWKV
- Тонкие протяженные структуры остаются наиболее сложными для линейных моделей

Общий вывод

Линейное внимание эффективно в сочетании с сверточными ветвями. Либо требует внедрения информации о топологии исходных данных.

Спасибо за внимание!

Салимли А. М.
salimli.am@edu.spbstu.ru

Список литературы

- [1] Xie E. et al. SegFormer // NeurIPS. 2021.
- [2] Sheng P. et al. LSNet // Neurocomputing. 2022.
- [3] Gu Y. et al. RTLinearFormer // Neurocomputing. 2025.
- [4] Guan S. et al. Hybrid linear attention // Pattern Recognition. 2026.
- [5] Fang Y. et al. A global linear attention network // Knowledge-Based Systems. 2026.
- [6] Zhang Z. et al. Dimensional collaborative linear-attention network // Adv. in Space Research. 2026.
- [7] Ye T. et al. LPT-Net // Measurement. 2024.
- [8] Zheng Z. et al. CA-UNet // Image and Vision Computing. 2026.
- [9] Yang Z. et al. Multi-scale linear cross-modal fusion // Comp. and Electr. in Agriculture. 2026.
- [10] Wu H. et al. FESS-SAM // Adv. Engineering Informatics. 2025.
- [11] Liu X. et al. MLFormer // Biomed. Signal Proc. and Control. 2026.
- [12] Wang L. et al. MASA-VMUNet // Expert Syst. with Appl. 2026.
- [13] Ge H. et al. WTP-MILA-UNet // Biomed. Signal Proc. and Control. 2026.
- [14] Uppal D., Prakash S. CLT-MambaSeg // Comp. in Biology and Medicine. 2025.
- [15] Yu C. et al. Topology-aware linear attention // Expert Syst. with Appl. 2026.
- [16] Chen Q. et al. UUEKAN // Biomed. Signal Proc. and Control. 2026.
- [17] Bai D. et al. Linear-complexity global context modeling // Expert Syst. with Appl. 2026.