УДК 004.032.26:004.932

УЛУЧШЕНИЕ ДЕКОДЕРА SEGFORMER ДЛЯ СЕМАНТИЧЕСКОЙ СЕГМЕНТАЦИИ С ПОМОЩЬЮ ДОБАВЛЕНИЯ БЛОКА ПОКАНАЛЬНОЙ СВЕРТКИ

Салимли Айзек Мухтар оглы

магистрант

ФГАОУ ВО «Санкт-Петербургский политехнический университет Петра Великого»

Научный руководитель: *Логунова А. В., старший преподаватель*

Аннотация: эффективные сети семантической сегментации обычно улучшают, модифицируя модуль смешивания токенов (token mixer) в энкодере. В контролируемом эксперименте на наборе данных Oxford-IIIT Pet четыре таких модуля встраиваются в одну и ту же архитектуру SegFormer-B0 и обучаются по единому протоколу. Модули, наследующие предобученные веса, достигают практически одинаковой точности (IoU класса границы различается не более чем на 0.0003), хотя их пропускная способность различается в шесть раз. Таким образом, модуль смешивания токенов определяет вычислительную стоимость модели, но не ее точность. Поклассовый анализ ошибок показывает, что точность ограничивает декодер. MLP-декодер SegFormer состоит только из сверток 1 × 1, поэтому его рецептивное поле на объединенной карте признаков равно одной позиции. Добавление одной поканальной свертки 3 × 3 после объединения признаков увеличивает число параметров всего на 2816 (0.08% модели), не увеличивает задержку сверх погрешности измерений и повышает mIoU с 0.8095 до 0.8161, IoU границы - с 0.6004 до 0.6137, масочную $mAP_{50:95}$ - с 0.8198 до 0.8270. Вклад этой свертки подтвержден парным абляционным экспериментом. Модифицированная модель также сравнивается с DeepLabV3+ и YOLOv8s-seg на общей бинарной задаче выделения переднего плана.

Ключевые слова: семантическая сегментация, визуальный трансформер, SegFormer, декодер, рецептивное поле, поканальная свертка.

IMPROVING THE SEGFORMER DECODER FOR SEMANTIC SEGMENTATION BY ADDING A DEPTHWISE CONVOLUTION BLOCK

Salimli Ayzek Muxtar oglu

Scientific adviser: *Logunova A. V.*

Abstract: efficient semantic segmentation networks are usually improved by modifying the token mixer of the encoder. In a controlled study on Oxford-IIIT Pet, four token mixers are substituted into an identical SegFormer-B0 architecture under a single training protocol. Mixers that inherit pretrained weights reach nearly identical accuracy (border-class IoU within 0.0003) while differing in throughput by a factor of six; the token mixer therefore determines the cost of the model but not its accuracy. A per-class error analysis locates the accuracy bottleneck in the decoder. The all-MLP decoder of SegFormer consists of 1 × 1 convolutions only, so its receptive field on the fused feature map equals one position. Inserting a single depthwise 3 × 3 convolution after the fusion step adds 2816 parameters (0.08% of the model) without measurable latency and raises mIoU from 0.8095 to 0.8161, border IoU from 0.6004 to 0.6137 and mask $mAP_{50:95}$ from 0.8198 to 0.8270. A paired ablation isolates the effect of this convolution. The modified model is also compared with DeepLabV3+ and YOLOv8s-seg under a shared binary foreground protocol.

Key words: semantic segmentation, vision transformer, SegFormer, decoder design, receptive field, depthwise convolution.

1. Введение

Семантическая сегментация сопоставляет каждому пикселю изображения $x \in \mathbb{R}^{3\times H\times W}$ метку класса $\hat{y}_{ij} = \mathrm{argmax}_c z_{cij}$, где $z \in \mathbb{R}^{C\times H\times W}$ - предсказанные логиты. Выход модели имеет то же пространственное разрешение, что и вход, поэтому модель должна одновременно учитывать глобальный семантический контекст и точно локализовать границы объектов.

Архитектура SegFormer [1] сочетает иерархический трансформерный энкодер с минималистичным декодером, построенным только из многослойных перцептронов (MLP), и обеспечивает хороший баланс между точностью и вычислительной эффективностью. В последующих работах ее, как правило, улучшают заменой модуля смешивания токенов (token mixer) в энкодере: на сканирование в пространстве состояний [2], линейное [3] или сверточное [4] внимание. За этим стоит неявное предположение, что точность сегментации определяется именно модулем смешивания токенов. В настоящей работе это предположение проверяется в контролируемых условиях, а затем, исходя из полученного результата, исследуется декодер.

Основные результаты работы:

1) контролируемое сравнение, показывающее, что при наследовании предобученных весов выбор модуля смешивания токенов практически не влияет на точность;

2) анализ рецептивного поля, показывающий, что точность модели ограничивает MLP-декодер;

3) модификация декодера одной поканальной сверткой 3 × 3 (далее - SegFormer-B0-DW), которая улучшает все метрики качества ценой 2816 дополнительных параметров.

2. Используемые архитектуры

Энкодер SegFormer. Энкодер MiT [1, 5, 6] обрабатывает перекрывающиеся фрагменты изображения (патчи) в четыре стадии с шагами 4, 8, 16, 32; в конфигурации B0 число каналов на стадиях равно 32, 64, 160, 256. Вычислительная сложность самовнимания по N токенам составляет $O(N^2 d)$. Чтобы ее снизить, в SegFormer ключи и значения пространственно сжимаются с коэффициентом R:

$$X' = \mathrm{SR}(X, R) \in \mathbb{R}^{(N/R^2)\times d}, \quad K = X'W_K, \qquad V = X'W_V,$$

благодаря чему сложность уменьшается до $O(N^2 d/R^2)$; по стадиям $R = 8,4,2,1$.

MLP-декодер. Пусть $F^{(k)} \in \mathbb{R}^{C_k \times H_k \times W_k}$ - выход стадии k. Декодер проецирует признаки каждой стадии в пространство общей размерности D, приводит их к разрешению с шагом 4 и объединяет:

$$U^{(k)} = \mathrm{Resize}\left(W_p^{(k)} *_{1\times1} F^{(k)}\right), \quad G = W_f *_{1\times1} \left[U^{(1)} \parallel U^{(2)} \parallel U^{(3)} \parallel U^{(4)}\right].$$

Далее следуют пакетная нормализация, функция активации ReLU, классификатор 1 × 1 и билинейная интерполяция с увеличением в четыре раза. Таким образом, все свертки декодера имеют ядро 1 × 1.

Модели для сравнения. DeepLabV3+ [7] использует энкодер ResNet-50 [8] и пирамиду разреженных (atrous) сверток, в которой ядро 3 × 3 с коэффициентом разрежения r охватывает $2r + 1$ позиций. YOLOv8-seg [9] - модель сегментации экземпляров, которая строит маски $m_n = \sigma(\sum_k \alpha_{n,k} P_k) \odot \mathbf{1}[b_n]$ как комбинацию общих прототипов P_k, обрезанную по ограничивающей рамке b_n. Такая постановка не позволяет описать классы, не являющиеся отдельными объектами, например граничное кольцо, используемое в данной работе. Поэтому сравнение с YOLOv8s-seg проводится на бинарной задаче выделения переднего плана.

3. Методика эксперимента

Данные и протокол обучения. Эксперименты проводились на наборе данных Oxford-IIIT Pet [10] с тремя классами: фон, животное и граница (кольцо неоднозначной разметки вокруг животного). Используется официальное разбиение: 3680 изображений для обучения (10% из них отведено для контроля обучения) и 3669 тестовых изображений; все изображения приводятся к размеру 256 × 256. Все модели обучаются оптимизатором AdamW [11] со скоростью обучения 3×10^{-4} (для предобученных параметров энкодера она уменьшается в 10 раз), коэффициентом затухания весов 0.01 и полиномиальным расписанием скорости обучения с разогревом на первых 5% шагов. Норма градиента ограничивается значением 1.0, размер батча равен 16, число эпох - 20. Используются аугментации: отражение, масштабирование с

обрезкой и изменение яркости. Функция потерь - попиксельная перекрестная энтропия; начальное значение генератора случайных чисел фиксировано (1337).

Метрики. Пусть TP_c, FP_c, FN_c - числа истинно положительных, ложноположительных и ложноотрицательных пикселей класса c, накопленные по всей тестовой выборке. Тогда

$$\mathrm{IoU}_c = \frac{\mathrm{TP}_c}{\mathrm{TP}_c + \mathrm{FP}_c + \mathrm{FN}_c}, \qquad \mathrm{Dice}_c = \frac{2\mathrm{TP}_c}{2\mathrm{TP}_c + \mathrm{FP}_c + \mathrm{FN}_c},$$

$$F_{\beta,c} = \frac{(1+\beta^2)P_c R_c}{\beta^2 P_c + R_c},$$

где P_c и R_c - точность и полнота; в работе используется $\beta = 2$. Масочная метрика $\mathrm{mAP}_{50:95}$ вычисляется по связным компонентам переднего плана как среднее значение AP (с интерполяцией по 101 точке) при порогах IoU 0.50, 0.55, ..., 0.95. Задержка определяется как среднее время 25 прямых проходов при размере батча 1 после 8 разогревочных проходов.

4. Влияние модуля смешивания токенов

Исходное эффективное самовнимание SegFormer [1] сравнивается с четырьмя альтернативными модулями смешивания токенов, встроенными в одну и ту же архитектуру: линейным вниманием со сжатыми ключами [3], вентильным вниманием с фиксированным бюджетом (ключи и значения сводятся к сетке 8 × 8), сверточным вниманием [4] и селективным сканированием в пространстве состояний [2]. Как видно из табл. 1, модули, наследующие предобученные веса проекций, достигают IoU класса границы от 0.6004 до 0.6006. Модули с иной параметризацией приходится инициализировать случайно, и их точность снижается. Если обучить одну и ту же архитектуру с унаследованными весами и без них, разница составит +0.1018 mIoU для линейного внимания и +0.0430 для внимания с фиксированным бюджетом, что больше разброса между любыми двумя модулями. Следовательно, модуль смешивания токенов определяет вычислительную стоимость вывода, но практически не влияет на точность.

Таблица 1

Модули смешивания токенов в одной архитектуре при едином протоколе обучения

Модуль смешивания токенов	**Наследование весов**	**mIoU**	**IoU границы**	**$mAP_{50:95}$**	**FPS**
Эффективное самовнимание	да	0.8095	0.6004	0.8198	156.9
Линейное внимание со сжатыми ключами	да	0.8093	0.6006	0.8190	136.1
Вентильное внимание с фиксированным бюджетом	да	0.8092	0.6005	0.8186	143.9
Сверточное внимание	нет	0.7871	0.5651	0.7826	141.2
Селективное сканирование в пространстве состояний	нет	0.7549	0.5202	0.7345	24.0

5. Модификация декодера

5.1. Анализ ошибок

Поклассовый IoU базовой модели составляет 0.9412 для фона, 0.8869 для животного и 0.6004 для границы. Две очевидные причины отставания класса границы удалось исключить. *Недостаточное разрешение декодера:* если пропустить эталонную разметку через то же «узкое место» с шагом 4 (унитарное кодирование, билинейное уменьшение и обратное увеличение, выбор наиболее вероятного класса), IoU границы составит 0.9101, что значительно выше, чем у модели. *Плохая калибровка:* умножение логита границы на 2.5 повышает IoU границы на 0.0095, но снижает mIoU с 0.7989 до 0.7956, а средняя предсказанная вероятность границы на граничных пикселях и так равна 0.6496. Следовательно, ошибка вызвана неточной локализацией кольца, а не разрешением или калибровкой.

5.2. Рецептивное поле декодера

Пусть $G \in \mathbb{R}^{D\times H/4\times W/4}$ - объединенная карта признаков, а ρ - рецептивное поле декодера на этой карте. Поскольку после объединения применяются только свертки 1 × 1, нормализация и поэлементные нелинейности,

$$z_{:,i,j} = g\left(G_{:,i,j}\right), \quad \rho = 1,$$

то есть каждая ячейка карты классифицируется независимо от соседних. Однако чтобы определить, лежит ли ячейка на границе объекта, нужна информация о соседних ячейках. Поканальная свертка 3 × 3 [12], добавленная после объединения, дает

$$z_{:,i,j} = g\left(\sum_{|a|\le 1}\sum_{|b|\le 1} w_{a,b} \odot G_{:,i+a,j+b}\right), \quad \rho = 3,$$

что соответствует 12 пикселям входного изображения. Блок содержит $D \times 3 \times 3 = 2304$ веса и 512 параметров нормализации, всего 2816 параметров против 3 714 915 у базовой модели. Итоговая архитектура показана на рис. 1.

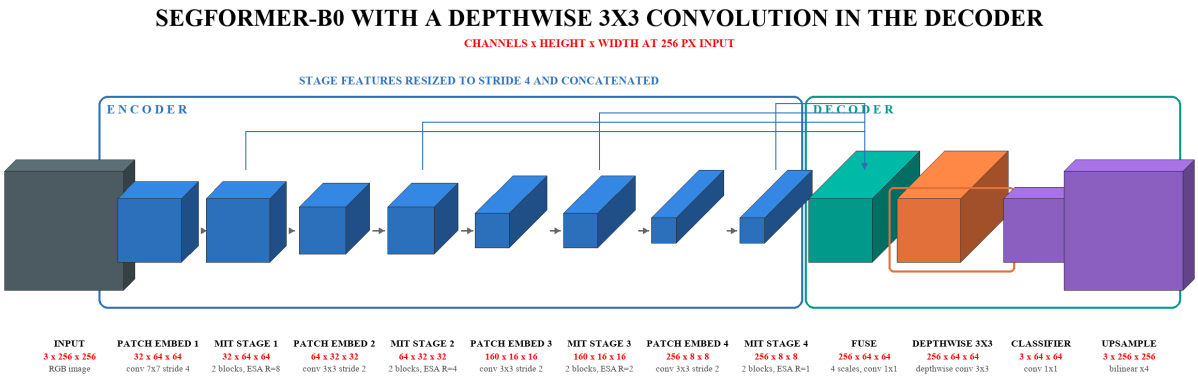


Рис. 1. Архитектура SegFormer-B0-DW: энкодер MiT-B0 и MLP-объединение признаков не изменены; между объединением и классификатором добавлена поканальная свертка 3 × 3.

6. Результаты

6.1. Парный абляционный эксперимент

Две модели, отличающиеся только наличием поканальной свертки, обучены с одинаковой шириной слоев, по одному протоколу и с одним и тем же начальным значением генератора случайных чисел (табл. 2). Наибольший прирост наблюдается для класса границы (+0.0121 IoU), тогда как для фона и животного он составляет 0.0021 и 0.0046. Это согласуется с анализом рецептивного поля: внутренние области объектов правильно классифицируются по одному вектору признаков, а для границ нужен контекст соседних позиций.

Таблица 2

Парный абляционный эксперимент: декодеры отличаются одной поканальной сверткой 3 × 3

Декодер	Параметры	mIoU	IoU границы	$mAP_{50:95}$	FPS
только 1 × 1, $\rho = 1$	3 714 915	0.8102	0.6016	0.8205	163.8
с поканальной сверткой 3 × 3, $\rho = 3$	3 717 731	**0.8161**	**0.6137**	**0.8270**	161.9
Разница	+2816	+0.0059	+0.0121	+0.0065	-1.9

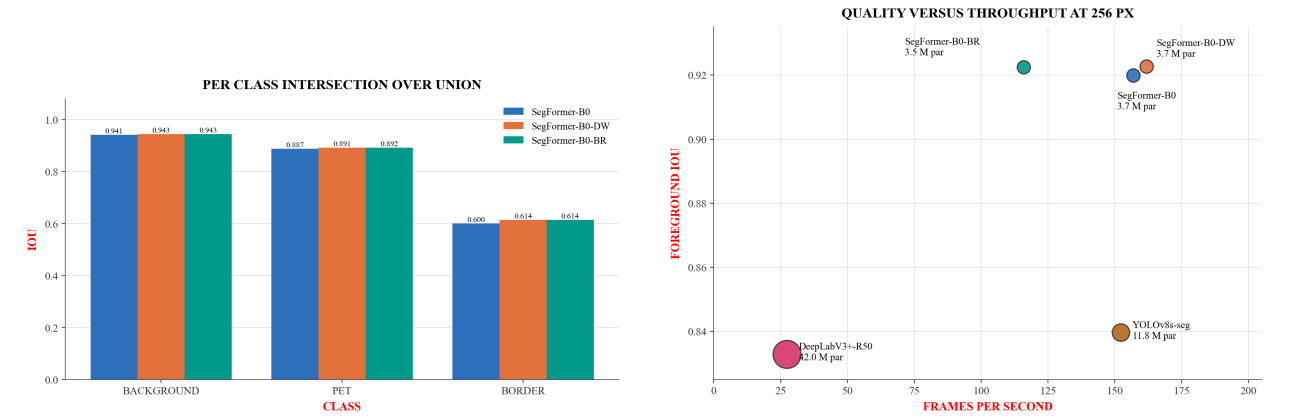
6.2. Сравнение с другими моделями

У DeepLabV3+ и YOLOv8s-seg нет класса границы, поэтому все модели дополнительно оцениваются на бинарной задаче выделения переднего плана, в которой классы «животное» и «граница» объединены; для моделей сравнения классы «кошка» и «собака» из VOC и COCO отнесены к переднему плану. Бинарные метрики моделей SegFormer рассчитаны по их трехклассовым матрицам ошибок (отклонение от прямого измерения не превышает 0.0003). Результаты сравнения приведены в табл. 3 и на рис. 2.

Таблица 3

Сравнение на тестовой выборке Oxford-IIIT Pet (3669 изображений); ПП - бинарная задача выделения переднего плана

Модель	Параметры	IoU ПП	Dice ПП	F2 ПП	$mAP_{50:95}$	mIoU	IoU границы	FPS
SegFormer-B0-DW	3.72 млн	**0.9227**	**0.9598**	**0.9569**	**0.8270**	**0.8161**	**0.6137**	**161.9**
SegFormer-B0-BR	3.50 млн	0.9225	0.9597	0.9560	0.8271	0.8162	0.6138	116.0
SegFormer-B0	3.71 млн	0.9199	0.9583	0.9558	0.8198	0.8095	0.6004	156.9
YOLOv8s-seg	11.82 млн	0.8397	0.9129	0.8801	0.6196	-	-	152.2
DeepLabV3+-R50	42.00 млн	0.8329	0.9088	0.8724	0.6398	-	-	27.4



а) поклассовый IoU

б) IoU переднего плана и пропускная способность

Рис. 2. Поклассовое качество сегментации и соотношение качества и пропускной способности сравниваемых моделей.

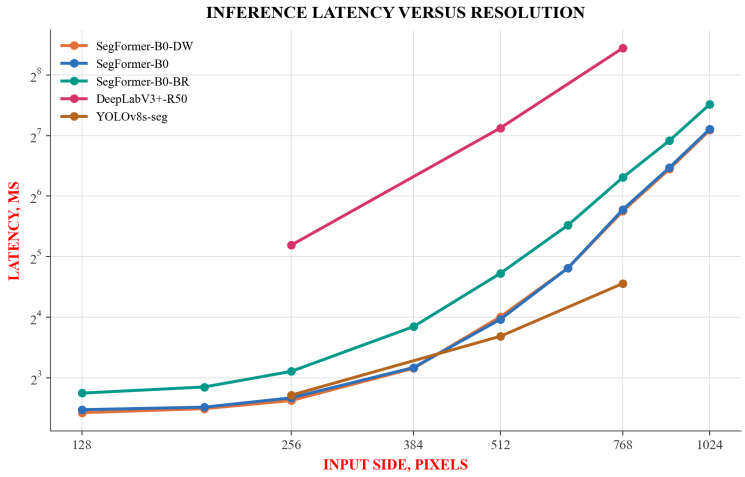


Рис. 3. Задержка вывода в зависимости от разрешения входного изображения.

SegFormer-B0-DW превосходит базовую модель по всем метрикам качества, при этом его задержка на всех разрешениях совпадает с задержкой базовой модели в пределах погрешности измерений (рис. 3). Модели сравнения оценивались по опубликованным весам без дообучения на данном наборе, поэтому разрыв около 0.08 по IoU переднего плана отражает эффект обучения на целевых данных, а не архитектурные недостатки этих моделей. DeepLabV3+ содержит в 11 раз больше параметров и работает в шесть раз медленнее, чем SegFormer-B0-DW. У YOLOv8s-seg самая низкая масочная AP (0.6196): если детектор пропускает объект, тот целиком исчезает из предсказания.

7. Обсуждение

Механизм улучшения. SegFormer-B0-BR в табл. 3 - альтернативный вариант декодера с ветвью деталей полного разрешения и обучаемым граничным вентилем: $z = z_{\text{сем}} + \sigma(b) \odot \Delta(\text{детали,семантика})$. Удаление вентиля вместе с отдельной функцией потерь для него не меняет mIoU (0.8167 против 0.8162); то же происходит при удалении ветви деталей (0.8163). Обе упрощенные версии сохраняют поканальную свертку в блоке объединения, которую парный эксперимент указывает как источник прироста. Значит, улучшение объясняется расширением рецептивного поля декодера, а не дополнительными ветвями, которые к тому же снижают пропускную способность со 161.9 до 116.0 кадров/с.

Ограничения. Оценка проведена на одном наборе данных с тремя классами и одним выраженным объектом на изображении, поэтому результаты могут не переноситься на ADE20K или Cityscapes. Базовой моделью служит дообученный SegFormer-B0, а не одна из лучших современных моделей. Все замеры времени выполнены на Apple Silicon с бэкендом Metal и на другом оборудовании могут отличаться. Модели сравнения на данном наборе не дообучались.

8. Заключение

При фиксированном протоколе обучения модули смешивания токенов, наследующие предобученные веса, обеспечивают практически одинаковую точность сегментации, хотя их пропускная способность различается в шесть раз. Точность SegFormer ограничивает MLP-декодер: его рецептивное поле на объединенной карте признаков равно одной позиции. Добавление всего одной поканальной свертки 3 × 3 после объединения расширяет рецептивное поле до трех позиций и повышает mIoU с 0.8095 до 0.8161, IoU границы - с 0.6004 до 0.6137, масочную $\text{mAP}_{50:95}$ - с 0.8198 до 0.8270. Цена улучшения - 2816 параметров без измеримого роста задержки.

Список источников

1. Xie E., Wang W., Yu Z., Anandkumar A., Alvarez J. M., Luo P. SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers // Advances in Neural Information Processing Systems (NeurIPS). - 2021. - Vol. 34. - P. 12077-12090.

2. Dao T., Gu A. Transformers are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality // Proceedings of the 41st International Conference on Machine Learning (ICML). - 2024. - P. 10041-10071.

3. Han D., Pan X., Han Y., Song S., Huang G. FLatten Transformer: Vision Transformer using Focused Linear Attention // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). - 2023. - P. 5938-5948.

4. Guo M.-H., Lu C.-Z., Hou Q., Liu Z., Cheng M.-M., Hu S.-M. SegNeXt: Rethinking Convolutional Attention Design for Semantic Segmentation // Advances in Neural Information Processing Systems (NeurIPS). - 2022. - Vol. 35. - P. 1140-1156.

5. Wang W., Xie E., Li X., Fan D.-P., Song K., Liang D., Lu T., Luo P., Shao L. Pyramid Vision Transformer: A Versatile Backbone for Dense Prediction without Convolutions // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). - 2021. - P. 548-558.

6. Wang W., Xie E., Li X., Fan D.-P., Song K., Liang D., Lu T., Luo P., Shao L. PVT v2: Improved Baselines with Pyramid Vision Transformer // Computational Visual Media. - 2022. - Vol. 8, № 3. - P. 415-424.

7. Chen L.-C., Zhu Y., Papandreou G., Schroff F., Adam H. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation // Computer Vision - ECCV 2018. Lecture Notes in Computer Science. - Cham: Springer, 2018. - P. 833-851.

8. He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). - 2016. - P. 770-778.

9. Jocher G., Chaurasia A., Qiu J. Ultralytics YOLOv8 [Electronic resource]. - Version 8.0.0. - 2023. - URL: https://github.com/ultralytics/ultralytics (accessed: 05.10.2026).

10. Parkhi O. M., Vedaldi A., Zisserman A., Jawahar C. V. Cats and Dogs // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). - 2012. - P. 3498-3505.

11. Loshchilov I., Hutter F. Decoupled Weight Decay Regularization // International Conference on Learning Representations (ICLR). - 2019.

12. Howard A. G., Zhu M., Chen B., Kalenichenko D., Wang W., Weyand T., Andreetto M., Adam H. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications // arXiv preprint arXiv:1704.04861. - 2017.

© А.М. Салимли, 2026